

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN**



BÁO CÁO ĐỒ ÁN CUỐI KÌ

DỰ ĐOÁN TỈ LỆ HỦY ĐẶT PHÒNG KHÁCH SẠN

GVHD : ThS. HÀ MINH TUẤN

Môn học : Python cho Khoa Học Dữ Liệu

Mã học phần : MTH10605

SINH VIÊN THỰC HIỆN:

Mai Thu Hương

23280061

Mục lục

1	Tổng quan hệ thống và bài toán	1
1.1	Đặt vấn đề và thách thức thực tế	1
1.2	Mục tiêu kỹ thuật và kinh doanh	1
1.2.1	Mục tiêu kinh doanh	1
1.2.2	Mục tiêu kỹ thuật	2
1.3	Tổng quan phương pháp tiếp cận	2
2	Kiến trúc phần mềm và tổ chức mã nguồn	3
2.1	Sơ đồ kiến trúc tổng thể dự án	3
2.2	Phân tách các module chức năng	3
2.2.1	Cấu hình hệ thống	3
2.2.2	Tiền xử lý dữ liệu	4
2.2.3	Huấn luyện và quản lý mô hình	4
2.2.4	Phân tích khám phá dữ liệu	4
2.3	Tập điều phối trung tâm	4
3	Khám phá dữ liệu và trực quan hóa	5
3.1	Nguồn dữ liệu	5
3.2	Kết quả khai phá dữ liệu	6
3.2.1	Phân phối và giá trị ngoại lai	6
3.2.2	Chân dung khách hàng	6
3.2.3	Các yếu tố ảnh hưởng đến việc hủy phòng	6
4	Tiền xử lý và hạn chế rò rỉ dữ liệu	11
4.1	Vòng đời xử lý dữ liệu	11
4.2	Kỹ thuật hạn chế rò rỉ dữ liệu	11
4.2.1	Phương thức <code>fit_transform()</code>	12
4.2.2	Phương thức <code>transform()</code>	12
4.3	Chiến lược lựa chọn và biến đổi đặc trưng	12

4.3.1	Loại bỏ biến có nguy cơ gây rò rỉ dữ liệu	12
4.3.2	Xử lý biến có chất lượng thông tin thấp	12
4.3.3	Tổng hợp đặc trưng có quan hệ logic	13
5	Huấn luyện, tối ưu và đánh giá mô hình	14
5.1	Thiết kế lớp điều phối theo hướng đối tượng	14
5.1.1	Tính đóng gói	15
5.1.2	Tính đa hình	16
5.1.3	Khả năng mở rộng	16
5.2	Các thuật toán học máy được thử nghiệm	16
5.3	Tối ưu siêu tham số	16
6	Đánh giá thực nghiệm và phân tích hiệu suất	18
6.1	So sánh hiệu suất tổng thể	18
6.1.1	Hiệu suất tổng thể	19
6.1.2	Khả năng phát hiện khách hủy phòng	19
6.1.3	Mức độ cân bằng giữa hai lớp	20
6.2	Phân tích đường cong ROC-AUC	20
6.3	Phân tích ma trận nhầm lẫn	21
6.3.1	LightGBM	21
6.3.2	Random Forest	21
6.3.3	XGBoost và CatBoost	22
6.4	Phân tích rủi ro và chiến lược kinh doanh	22
6.4.1	Rủi ro vận hành	22
6.4.2	Đề xuất chiến lược ứng dụng	22
7	Kết luận và ứng dụng thực tiễn	23
7.1	Tổng kết giải pháp	23
7.2	Đề xuất chiến lược kinh doanh	23
7.2.1	Điều chỉnh ngưỡng quyết định	23
7.2.2	Chăm sóc khách hàng chủ động	24
7.2.3	Quản lý bán dư phòng	24
7.3	Hạn chế của nghiên cứu	24
7.3.1	Phạm vi dữ liệu	24
7.3.2	Khả năng giải thích mô hình	24
7.4	Hướng phát triển	24

Danh mục hình ảnh

3.1	Biểu đồ thể hiện giá trị ngoại lai của các biến số quan trọng	6
3.2	Phân phối của các biến số quan trọng	7
3.3	Thống kê các nhóm khách hàng theo biến phân loại	7
3.4	10 quốc gia có số lượng khách hàng lớn nhất	8
3.5	Ma trận tương quan giữa các biến số và trạng thái hủy phòng	8
3.6	Mật độ phân phối thời gian đặt trước giữa hai nhóm khách hàng	9
3.7	Mối quan hệ giữa số lượng yêu cầu đặc biệt và trạng thái hủy phòng	9
3.8	Mối quan hệ giữa loại đặt cọc và trạng thái hủy phòng	10
3.9	Tỷ lệ hủy phòng theo từng phân khúc thị trường	10
5.1	Kiến trúc lớp điều phối ModelTrainer	15
6.1	So sánh độ chính xác của các mô hình (<i>Model Accuracy Comparison</i>)	19
6.2	Đường cong ROC so sánh các mô hình (<i>ROC Curve Comparison</i>)	20
6.3	Ma trận nhầm lẫn của bốn mô hình học máy	21

Danh mục bảng biểu

6.1a	Kết quả đánh giá các mô hình đối với lớp không hủy phòng	18
6.1b	Kết quả đánh giá các mô hình đối với lớp hủy phòng	19

Chương 1

Tổng quan hệ thống và bài toán

1.1 Đặt vấn đề và thách thức thực tế

Trong hoạt động kinh doanh khách sạn và dịch vụ lưu trú, việc khách hàng hủy đặt phòng, đặc biệt ở thời điểm gần ngày nhận phòng, gây ra nhiều khó khăn cho công tác vận hành và quản trị doanh thu. Khách hàng có thể hủy đặt phòng do thay đổi kế hoạch cá nhân, lựa chọn được mức giá phù hợp hơn hoặc chưa có cam kết tài chính tại thời điểm đặt chỗ.

Việc hủy phòng làm phát sinh nguy cơ thất thoát doanh thu vì phòng đã được giữ chỗ có thể không kịp bán lại, nhất là trong mùa cao điểm. Đồng thời, chênh lệch giữa số lượng đặt phòng và số lượng khách thực tế làm giảm độ tin cậy của dự báo doanh thu, ảnh hưởng đến kế hoạch phân bổ phòng, nhân sự và các nguồn lực vận hành. Hiện tượng này cũng gây khó khăn cho quá trình điều chỉnh giá và tối ưu công suất phòng.

Trong bối cảnh đó, việc ứng dụng các phương pháp học máy để nhận diện sớm những đơn đặt phòng có nguy cơ bị hủy có thể cung cấp thêm cơ sở định lượng cho quá trình ra quyết định. Kết quả dự đoán hỗ trợ khách sạn chủ động xây dựng chính sách đặt cọc, chăm sóc khách hàng và phân bổ phòng phù hợp với từng nhóm rủi ro.

1.2 Mục tiêu kỹ thuật và kinh doanh

Đề tài hướng đến hai nhóm mục tiêu có mối quan hệ hỗ trợ, bao gồm mục tiêu kinh doanh và mục tiêu kỹ thuật.

1.2.1 Mục tiêu kinh doanh

Về phương diện kinh doanh, đề tài tập trung nhận diện sớm các đặt phòng có rủi ro hủy cao nhằm hỗ trợ khách sạn điều chỉnh kế hoạch phân bổ phòng và cân nhắc chính sách đặt dư (*overbooking*) ở mức phù hợp. Kết quả dự đoán cũng có thể được sử dụng để xây dựng kế hoạch bán phòng linh hoạt, cải thiện tỷ lệ lấp đầy và giảm thiểu tổn thất doanh thu. Bên cạnh đó, việc phân nhóm theo mức độ rủi ro tạo cơ sở cho các chính sách chăm sóc khách hàng hoặc yêu cầu đặt cọc trước.

1.2.2 Mục tiêu kỹ thuật

Về phương diện kỹ thuật, đề tài xây dựng một quy trình xử lý khép kín (*end-to-end pipeline*) bằng Python và tổ chức mã nguồn theo hướng đối tượng. Quy trình bao gồm các bước làm sạch dữ liệu, xử lý giá trị thiếu và ngoại lai, hạn chế nguy cơ rò rỉ dữ liệu, huấn luyện mô hình và đánh giá kết quả. Các thuật toán *Random Forest*, *XGBoost*, *LightGBM* và *CatBoost* được thử nghiệm và tinh chỉnh siêu tham số để thực hiện so sánh trên cùng một tập tiêu chí đánh giá.

1.3 Tổng quan phương pháp tiếp cận

Để giải quyết bài toán phân loại nhị phân dự đoán khả năng hủy phòng (`is_canceled`), nghiên cứu được triển khai theo bốn giai đoạn chính:

1. **Khám phá và phân tích dữ liệu:** Khảo sát cấu trúc dữ liệu, phân phối của các biến định lượng và định tính, đồng thời xác định những đặc trưng có liên hệ với hành vi hủy phòng.
2. **Thiết kế quy trình tiền xử lý:** Xây dựng lớp `DataPreprocessor` để thực hiện trích xuất đặc trưng, chuẩn hóa, mã hóa biến phân loại và loại bỏ các đặc trưng có khả năng gây nhiễu hoặc rò rỉ thông tin.
3. **Huấn luyện và quản lý mô hình:** Tổ chức các thành phần tinh chỉnh tham số, đánh giá hiệu năng và lưu trữ mô hình thành những module độc lập, qua đó hỗ trợ việc thử nghiệm và lựa chọn mô hình.
4. **Đánh giá thực nghiệm:** So sánh các mô hình thông qua Accuracy, Precision, Recall, Macro F1-score, ROC-AUC và ma trận nhầm lẫn; từ kết quả này, nghiên cứu đề xuất định hướng ứng dụng trong hoạt động quản lý khách sạn.

Chương 2

Kiến trúc phần mềm và tổ chức mã nguồn

Nhằm nâng cao khả năng bảo trì, tái sử dụng và mở rộng, mã nguồn của dự án được tổ chức thành các module có trách nhiệm riêng biệt. Cách tổ chức này vận dụng các nguyên lý cơ bản của lập trình hướng đối tượng và kiến trúc phần mềm phân tầng.

2.1 Sơ đồ kiến trúc tổng thể dự án

Hệ thống được thiết kế theo mô hình phân tầng (*Layered Architecture*), chia tách rõ ràng giữa tầng cấu hình (`config`), tầng xử lý dữ liệu thô và mô hình (`src`), cùng tầng lưu trữ kết quả đầu ra (`data`, `models`, `reports`).

Luồng dữ liệu (*data flow*) bắt đầu từ tập dữ liệu thô `hotel_bookings.csv`. Dữ liệu được chuyển qua quy trình tiền xử lý để hình thành tập huấn luyện và tập kiểm thử, sau đó được đưa vào các mô hình học máy. Kết quả của quá trình phân tích và huấn luyện được lưu tại các thư mục đầu ra tương ứng, bao gồm mô hình đã huấn luyện, hình ảnh trực quan hóa và báo cáo.

2.2 Phân tách các module chức năng

Mã nguồn trong thư mục `src/` được phân chia theo chức năng nhằm hạn chế sự phụ thuộc giữa các thành phần và tạo thuận lợi cho việc kiểm thử.

2.2.1 Cấu hình hệ thống

Thư mục `config/` lưu trữ các thiết lập dùng chung. Tập `config.ini` quản lý siêu tham số và đường dẫn của dữ liệu huấn luyện, kiểm thử; trong khi đó, `settings.py` định nghĩa các hằng số, đường dẫn lưu trữ, cấu hình nhật ký (*logging*) và bảng màu sử dụng trong phân tích khám phá dữ liệu.

2.2.2 Tiền xử lý dữ liệu

Tệp `preprocessing.py` đóng gói quy trình làm sạch dữ liệu trong lớp `DataPreprocessor`. Thành phần này thực hiện chuẩn hóa tên cột, xử lý giá trị thiếu, phát hiện ngoại lai, mã hóa biến phân loại và chuẩn hóa các biến số. Việc tập trung các thao tác tiền xử lý trong một lớp thống nhất giúp bảo đảm cùng một quy trình được áp dụng cho dữ liệu huấn luyện và dữ liệu kiểm thử.

2.2.3 Huấn luyện và quản lý mô hình

Gói `src/training/` gồm ba module chính. Tệp `tuner.py` chứa lớp `ModelTuner`, chịu trách nhiệm thiết lập không gian tìm kiếm và tinh chỉnh siêu tham số bằng *RandomizedSearchCV*. Tệp `evaluator.py` chứa lớp `ModelEvaluator`, thực hiện tính toán các chỉ số đánh giá và tạo biểu đồ đường cong ROC, ma trận nhầm lẫn và biểu đồ so sánh. Tệp `model_manager.py` đảm nhiệm việc lưu, tải mô hình ở định dạng `.pkl` và trích xuất mức độ quan trọng của đặc trưng.

2.2.4 Phân tích khám phá dữ liệu

Nhóm module phân tích khám phá dữ liệu gồm `eda_processor.py`, `eda_visualizer.py` và `eda_reporter.py`. Các module này lần lượt đảm nhiệm việc xử lý dữ liệu phục vụ phân tích, xây dựng biểu đồ thống kê và tổng hợp kết quả thành báo cáo HTML `FULL_EDA_REPORT.html`.

2.3 Tập điều phối trung tâm

Quy trình từ phân tích khám phá dữ liệu, tiền xử lý đến huấn luyện mô hình được điều khiển thông qua tệp `main.py` tại thư mục gốc của dự án.

Thư viện `argparse` được sử dụng để cung cấp các chế độ thực thi độc lập trên dòng lệnh. Các lệnh chính gồm:

- `python main.py -eda`: Kích hoạt luồng phân tích khám phá dữ liệu và xuất báo cáo HTML.
- `python main.py -preprocess`: Thực hiện làm sạch và chuẩn bị dữ liệu cho Machine Learning.
- `python main.py -tune -model Auto`: Tinh chỉnh và so sánh các thuật toán học máy đã cấu hình.

Cách tổ chức trên hỗ trợ tái lập quy trình thực nghiệm (*reproducibility*) và cho phép từng giai đoạn được thực thi, kiểm tra hoặc mở rộng tương đối độc lập.

Chương 3

Khám phá dữ liệu và trực quan hóa

Quá trình phân tích khám phá dữ liệu (*Exploratory Data Analysis – EDA*) cung cấp cái nhìn tổng quan về cấu trúc, phân phối và các mối quan hệ trong tập dữ liệu đặt phòng khách sạn. Kết quả của giai đoạn này là cơ sở cho việc lựa chọn phương pháp tiền xử lý, xây dựng đặc trưng và thiết kế mô hình dự đoán.

3.1 Nguồn dữ liệu

Dữ liệu sử dụng trong nghiên cứu được thu thập từ bộ dữ liệu *Hotel Booking Demand* trên nền tảng Kaggle. Bộ dữ liệu có thể được truy cập tại **Kaggle – Hotel Booking Demand**.

Tập dữ liệu gồm 119 391 quan sát và 32 biến, trong đó có 31 đặc trưng mô tả thông tin khách hàng, giao dịch và đặt phòng; biến còn lại là biến mục tiêu phục vụ bài toán phân loại. Các đặc trưng đầu vào ban đầu được phân thành năm nhóm chính như sau:


1. **Thông tin khách hàng và đặt phòng:** `hotel`, `lead_time`, `arrival_date_year`, `arrival_date_month`, `arrival_date_week_number`, `arrival_date_day_of_month`, `stays_in_weekend_nights`, `stays_in_week_nights`, `adults`, `children`, `babies`, `meal`, `country`, `market_segment`, `distribution_channel`, `is_repeated_guest`, `previous_cancellations`, `previous_bookings_not_canceled`, `reserved_room_type`, `assigned_room_type` và `booking_changes`.
2. **Thông tin giao dịch và thanh toán:** `deposit_type`, `agent` và `company`.
3. **Thông tin về thời gian chờ và loại khách hàng:** `days_in_waiting_list` và `customer_type`.
4. **Thông tin về giá, cơ sở vật chất và yêu cầu đặt phòng:** `adr`, `required_car_parking_spaces` và `total_of_special_requests`.
5. **Thông tin trạng thái đặt phòng:** `reservation_status` và `reservation_status_date`. Do các biến này có thể phản ánh kết quả sau khi trạng thái đặt phòng đã được xác định, khả năng gây rò rỉ dữ liệu của chúng được xem xét trong giai đoạn tiền xử lý.

Biến đầu ra của bài toán là `is_canceled`. Đây là biến nhị phân nhận giá trị 0 nếu đơn đặt phòng không bị hủy và nhận giá trị 1 nếu đơn đặt phòng bị hủy.

3.2 Kết quả khai phá dữ liệu

3.2.1 Phân phối và giá trị ngoại lai

Các biến định lượng quan trọng, gồm giá phòng trung bình theo ngày (`adr`), thời gian đặt trước (`lead_time`) và tổng số đêm lưu trú (`total_nights`), được khảo sát bằng biểu đồ hộp và biểu đồ phân phối tần suất. Kết quả giúp nhận diện hình dạng phân phối, mức độ phân tán và các quan sát có giá trị khác biệt đáng kể so với phần lớn dữ liệu.




Hình 3.1: Biểu đồ thể hiện giá trị ngoại lai của các biến số quan trọng

3.2.2 Chân dung khách hàng


Việc phân tích các biến định tính hỗ trợ mô tả nguồn gốc khách hàng, loại hình lưu trú và các kênh phân phối được sử dụng trong quá trình đặt phòng. Các kết quả này cung cấp bối cảnh cho việc diễn giải hành vi của từng nhóm khách hàng trong tập dữ liệu.

3.2.3 Các yếu tố ảnh hưởng đến việc hủy phòng


Ma trận tương quan và các biểu đồ phân phối được sử dụng để khảo sát mối liên hệ giữa khả năng hủy phòng với thời gian đặt trước (`lead_time`), loại đặt cọc (`deposit_type`), phân khúc thị trường và số lượng yêu cầu đặc biệt (`total_of_special_requests`). Các kết quả được diễn giải theo hướng mô tả và không được xem là bằng chứng trực tiếp về quan hệ nhân quả.




Hình 3.2: Phân phối của các biến số quan trọng




Hình 3.3: Thống kê các nhóm khách hàng theo biến phân loại




Hình 3.4: 10 quốc gia có số lượng khách hàng lớn nhất




Hình 3.5: Ma trận tương quan giữa các biến số và trạng thái hủy phòng




Hình 3.6: Mật độ phân phối thời gian đặt trước giữa hai nhóm khách hàng



Hình 3.7: Mối quan hệ giữa số lượng yêu cầu đặc biệt và trạng thái hủy phòng



Hình 3.8: Mối quan hệ giữa loại đặt cọc và trạng thái hủy phòng



Hình 3.9: Tỷ lệ hủy phòng theo từng phân khúc thị trường

Xem báo cáo EDA chi tiết tại đây: **FULL_EDA_REPORT**.

Chương 4

Tiền xử lý và hạn chế rò rỉ dữ liệu

4.1 Vòng đời xử lý dữ liệu

Quá trình chuẩn bị dữ liệu có ảnh hưởng trực tiếp đến chất lượng đầu vào và độ tin cậy của mô hình học máy. Trong nghiên cứu này, quy trình xử lý được thiết kế theo một chuỗi biến đổi thống nhất từ dữ liệu thô đến dữ liệu sẵn sàng cho huấn luyện. Các bước chính gồm:

1. **Chuẩn hóa tên cột:** Tên đặc trưng được chuyển về dạng `snake_case`, đồng thời loại bỏ khoảng trắng và các ký tự không cần thiết. Cách biểu diễn thống nhất giúp giảm lỗi khi truy xuất biến và tăng khả năng tương thích với các thư viện xử lý dữ liệu, huấn luyện mô hình.
2. **Trích xuất đặc trưng thời gian:** Các cột thời gian, nếu có, được phân rã thành những thành phần như năm, tháng, ngày và thứ trong tuần. Việc giữ hoặc loại bỏ biến thời gian gốc được quyết định dựa trên ý nghĩa của biến và nguy cơ trùng lặp thông tin, thay vì áp dụng một quy tắc loại bỏ cố định.
3. **Xử lý giá trị thiếu:** Chiến lược điền khuyết được lựa chọn theo kiểu dữ liệu và đặc điểm phân phối. Các biến số có thể sử dụng giá trị trung bình hoặc trung vị; các biến phân loại có thể sử dụng giá trị xuất hiện nhiều nhất hoặc một nhãn riêng như `Unknown`. Tham số điền khuyết chỉ được ước lượng từ tập huấn luyện.
4. **Mã hóa và chuẩn hóa dữ liệu:** Các biến phân loại được chuyển sang dạng số bằng mã hóa nhãn, mã hóa tần suất hoặc mã hóa one-hot tùy thuộc vào số lượng giá trị phân biệt và yêu cầu của thuật toán. Các biến số được chuẩn hóa khi phương pháp học máy nhạy cảm với thang đo của đặc trưng.

4.2 Kỹ thuật hạn chế rò rỉ dữ liệu

Rò rỉ dữ liệu xảy ra khi thông tin không nên có ở thời điểm huấn luyện hoặc dự đoán được đưa vào quá trình xây dựng mô hình. Một trường hợp phổ biến là sử dụng thống kê của tập kiểm thử để điền khuyết, chuẩn hóa hoặc mã hóa dữ liệu. Khi đó, kết quả đánh giá có thể cao hơn năng lực khái quát thực tế của mô hình.

Để hạn chế hiện tượng này, lớp `DataPreprocessor` phân tách rõ giai đoạn học tham số và giai đoạn áp dụng phép biến đổi.

4.2.1 Phương thức `fit_transform()`

Phương thức `fit_transform()` được thực thi trên tập huấn luyện. Tại bước này, bộ tiền xử lý ước lượng các tham số cần thiết, chẳng hạn giá trị dùng để điền khuyết, giá trị nhỏ nhất và lớn nhất hoặc trung bình và độ lệch chuẩn để chuẩn hóa, cùng tập giá trị của các biến phân loại. Những tham số này được lưu trong đối tượng để sử dụng nhất quán ở các bước sau.

4.2.2 Phương thức `transform()`

Phương thức `transform()` được áp dụng cho tập kiểm thử hoặc dữ liệu mới. Phương thức chỉ sử dụng các tham số đã được ước lượng từ tập huấn luyện và không tính toán lại thống kê trên dữ liệu đầu vào. Cơ chế này mô phỏng phù hợp hơn điều kiện suy luận, trong đó hệ thống phải xử lý những quan sát chưa xuất hiện trong quá trình huấn luyện.

Việc phân tách hai phương thức trên giúp giảm nguy cơ rò rỉ dữ liệu trong giai đoạn tiền xử lý. Tuy nhiên, độ tin cậy của kết quả còn phụ thuộc vào thời điểm chia dữ liệu, cách thực hiện kiểm định chéo và việc loại bỏ các biến chứa thông tin phát sinh sau thời điểm dự đoán.

4.3 Chiến lược lựa chọn và biến đổi đặc trưng

Bên cạnh các thao tác làm sạch cơ bản, nghiên cứu thực hiện lựa chọn và tổng hợp đặc trưng nhằm giảm thông tin dư thừa, hạn chế rò rỉ và cải thiện khả năng khái quát của mô hình.

4.3.1 Loại bỏ biến có nguy cơ gây rò rỉ dữ liệu

Các biến phản ánh kết quả chỉ có sau khi quá trình đặt phòng đã hoàn tất không được sử dụng làm đầu vào. Nhóm này gồm trạng thái cuối cùng của đơn đặt phòng (`reservation_status`), ngày cập nhật trạng thái (`reservation_status_date`) và loại phòng thực tế được giao (`assigned_room_type`). Việc loại bỏ các biến này bảo đảm mô hình chỉ sử dụng thông tin có thể quan sát tại thời điểm cần đưa ra dự đoán.

4.3.2 Xử lý biến có chất lượng thông tin thấp

Các cột có tỷ lệ thiếu rất cao hoặc mang tính định danh cần được đánh giá trước khi đưa vào mô hình. Chẳng hạn, biến `company` thiếu hơn 90% số quan sát, còn `agent` có thể chứa nhiều mã đại lý riêng lẻ. Những biến này được loại bỏ khi thông tin bổ sung không đủ bù

đáp độ phức tạp và nguy cơ mô hình ghi nhớ các mẫu riêng biệt. Biến `arrival_date_year` cũng được xem xét trong bối cảnh phạm vi thời gian của dữ liệu và mục tiêu triển khai.

4.3.3 Tổng hợp đặc trưng có quan hệ logic


Các biến có quan hệ về mặt ngữ nghĩa được tổng hợp để tạo biểu diễn cô đọng hơn. Số đêm cuối tuần và số đêm ngày thường được cộng thành `total_nights`; số lượng người lớn, trẻ em và trẻ sơ sinh được tổng hợp thành `total_guests`; đồng thời biến `has_children` biểu diễn việc đơn đặt phòng có trẻ em hay không. Hiệu quả của các đặc trưng phái sinh được đánh giá bằng thực nghiệm thay vì giả định trước rằng chúng luôn cải thiện mô hình.

Chương 5

Huấn luyện, tối ưu và đánh giá mô hình

5.1 Thiết kế lớp điều phối theo hướng đối tượng

Quy trình nạp dữ liệu đã tiền xử lý, phân chia tập dữ liệu, tinh chỉnh siêu tham số, huấn luyện và lưu trữ mô hình được điều phối thông qua lớp `ModelTrainer` cùng các module phụ trợ trong gói `src/training/`. Cách tổ chức này nhằm tách biệt trách nhiệm giữa các thành phần và tạo điều kiện cho việc kiểm thử, bảo trì và mở rộng hệ thống.



Hình 5.1: Kiến trúc lớp điều phối ModelTrainer

5.1.1 Tính đóng gói

Trạng thái vận hành, thông tin cấu hình và các phương thức xử lý được quản lý bên trong đối tượng huấn luyện. Người sử dụng tương tác với hệ thống thông qua các phương thức công khai, trong khi chi tiết triển khai và các biến nội bộ được giới hạn trong phạm vi của lớp. Cơ chế đóng gói giúp giảm sự phụ thuộc giữa mã điều phối và từng thuật toán cụ thể.

5.1.2 Tính đa hình

Các mô hình tuân theo giao diện tương thích với thư viện *scikit-learn*. Nhờ đó, *Random Forest*, *XGBoost*, *LightGBM* và *CatBoost* có thể được huấn luyện và dự đoán thông qua các phương thức thống nhất như `fit()` và `predict()`. Cách tiếp cận này cho phép thay đổi thuật toán mà không làm thay đổi đáng kể luồng điều phối.

5.1.3 Khả năng mở rộng

Cấu trúc module cho phép bổ sung thuật toán hoặc phương pháp đánh giá mới thông qua việc mở rộng cấu hình và thành phần tương ứng. Logic điều phối chính được giữ tương đối ổn định, qua đó hạn chế ảnh hưởng của thay đổi đến các phần còn lại của hệ thống.

5.2 Các thuật toán học máy được thử nghiệm

Để giải quyết bài toán phân loại nhị phân, nghiên cứu thử nghiệm bốn thuật toán học máy dựa trên cây quyết định:

1. **Random Forest:** Đây là thuật toán thuộc nhóm *bagging*, xây dựng nhiều cây quyết định trên các mẫu dữ liệu và tập đặc trưng được lựa chọn ngẫu nhiên. Kết quả phân loại cuối cùng được xác định bằng cơ chế bỏ phiếu giữa các cây, qua đó góp phần giảm phương sai so với một cây quyết định đơn lẻ.
2. **XGBoost (*Extreme Gradient Boosting*):** Thuật toán xây dựng tuần tự các cây nhằm hiệu chỉnh sai số của mô hình trước đó. Hàm mục tiêu kết hợp hàm mất mát với các thành phần điều chuẩn L1 và L2 để kiểm soát độ phức tạp của mô hình.
3. **LightGBM (*Light Gradient Boosting Machine*):** LightGBM là một khung tăng cường gradient sử dụng các kỹ thuật như lấy mẫu một phía dựa trên gradient (GOSS) và gộp các đặc trưng loại trừ lẫn nhau (EFB). Các kỹ thuật này hướng đến việc giảm chi phí tính toán trên tập dữ liệu có kích thước lớn hoặc nhiều đặc trưng.
4. **CatBoost (*Categorical Boosting*):** CatBoost hỗ trợ xử lý biến phân loại thông qua cơ chế tăng cường có thứ tự (*ordered boosting*) và sử dụng cấu trúc cây đối xứng. Thuật toán được đưa vào so sánh để đánh giá khả năng khai thác các đặc trưng phân loại trong dữ liệu đặt phòng.

5.3 Tối ưu siêu tham số

Siêu tham số ảnh hưởng đến độ phức tạp, khả năng khái quát và chi phí huấn luyện của từng thuật toán. Trong nghiên cứu này, module `tuner.py` sử dụng *RandomizedSearchCV* để lấy mẫu các cấu hình từ không gian tham số đã xác định. Mỗi cấu hình được đánh giá

bằng kiểm định chéo trên tập huấn luyện; tập kiểm thử không tham gia vào quá trình lựa chọn siêu tham số.

Không gian tìm kiếm bao gồm các tham số tiêu biểu như độ sâu cây `max_depth`, tốc độ học `learning_rate` và số lượng lá tối đa `num_leaves`. Cấu hình được lựa chọn dựa trên thước đo đánh giá đã xác định trước, sau đó mô hình được huấn luyện lại trên toàn bộ tập huấn luyện để thực hiện đánh giá cuối cùng.

Chương 6

Đánh giá thực nghiệm và phân tích hiệu suất

Chương này trình bày kết quả đánh giá và so sánh các mô hình học máy trên tập kiểm thử độc lập. Bên cạnh các thước đo thống kê, đường cong ROC, ma trận nhầm lẫn và những rủi ro nghiệp vụ liên quan cũng được phân tích nhằm lựa chọn mô hình phù hợp với bài toán quản lý khách sạn.

6.1 So sánh hiệu suất tổng thể

Sau quá trình huấn luyện và tối ưu siêu tham số trên tập huấn luyện, các mô hình *LightGBM*, *CatBoost*, *XGBoost* và *Random Forest* được đánh giá bằng Accuracy, Precision, Recall, F1-score và điểm kiểm định chéo (CV Score).

Model	Best_CV_Score	Accuracy	Precision_0	Recall_0	F1_Score_0
LightGBM	0,8256	0,8325	0,8661	0,9097	0,8873
CatBoost	0,8247	0,8305	0,8614	0,9132	0,8866
RandomForest	0,8218	0,8289	0,8559	0,9188	0,8862
XGBoost	0,8209	0,8289	0,8653	0,909	0,8846


Bảng 6.1a: Kết quả đánh giá các mô hình đối với lớp không hủy phòng

Model	Precision_1	Recall_1	F1_Score_1	Macro_Avg_F1
LightGBM	0,7252	0,6289	0,6737	0,78049
CatBoost	0,7279	0,6125	0,6652	0,7759
RandomForest	0,7343	0,5919	0,6555	0,7708
XGBoost	0,7146	0,6285	0,6688	0,7767

Bảng 6.1b: Kết quả đánh giá các mô hình đối với lớp hủy phòng

6.1.1 Hiệu suất tổng thể

Accuracy của các thuật toán dao động từ 82,89% đến 83,25%. LightGBM đạt Accuracy cao nhất là 83,25% và CV Score cao nhất là 0,8256. Tuy nhiên, chênh lệch Accuracy giữa mô hình này và Random Forest hoặc XGBoost chỉ bằng 0,36 điểm phần trăm. Vì vậy, hiệu suất tổng thể của bốn mô hình trên tập dữ liệu khảo sát tương đối gần nhau.



Hình 6.1: So sánh độ chính xác của các mô hình (*Model Accuracy Comparison*)

6.1.2 Khả năng phát hiện khách hủy phòng

Recall của lớp 1 là chỉ số quan trọng khi chi phí bỏ sót một trường hợp hủy cao hơn chi phí cảnh báo nhầm. LightGBM đạt Recall 62,89%, tương đương với việc nhận diện đúng gần 63% số trường hợp hủy trong tập kiểm thử. XGBoost có kết quả gần tương đương với Recall 62,85%, trong khi Random Forest đạt giá trị thấp nhất là 59,19%. Kết quả cho thấy

Random Forest đưa ra dự đoán hủy thận trọng hơn, thể hiện qua Precision lớp 1 cao nhưng Recall thấp hơn.


6.1.3 Mức độ cân bằng giữa hai lớp

LightGBM đạt Macro F1 cao nhất là 0,7805, tiếp theo là XGBoost với 0,7767, CatBoost với 0,7759 và Random Forest với 0,7708. Theo chỉ số này, LightGBM duy trì sự cân bằng tốt nhất giữa hai lớp trong nhóm mô hình khảo sát, mặc dù mức chênh lệch không lớn.

6.2 Phân tích đường cong ROC-AUC

Đường cong ROC (*Receiver Operating Characteristic*) và diện tích dưới đường cong (AUC) được sử dụng để đánh giá khả năng phân biệt hai lớp tại nhiều ngưỡng quyết định.


Các mô hình đạt AUC xấp xỉ 0,89, cho thấy khả năng phân biệt tương đối tốt giữa lớp hủy và lớp không hủy. LightGBM đạt AUC cao nhất là 0,895 trong phạm vi thực nghiệm. Tuy nhiên, mức chênh lệch AUC giữa các mô hình cần được xem xét cùng với độ ổn định qua các lần chia dữ liệu và khoảng tin cậy của chỉ số.



Hình 6.2: Đường cong ROC so sánh các mô hình (*ROC Curve Comparison*)

6.3 Phân tích ma trận nhầm lẫn

Ma trận nhầm lẫn cung cấp số lượng dự đoán đúng và sai của từng lớp, qua đó cho phép liên hệ kết quả kỹ thuật với rủi ro vận hành.



Hình 6.3: Ma trận nhầm lẫn của bốn mô hình học máy

6.3.1 LightGBM

LightGBM dự đoán đúng 3022 trường hợp hủy phòng và bỏ sót 1783 trường hợp. Trong bốn mô hình, đây là số dự đoán đúng lớp hủy cao nhất và số âm tính giả thấp nhất, phù hợp với kết quả Recall lớp 1 đã phân tích ở trên.

6.3.2 Random Forest

Random Forest có Precision lớp 1 cao nhất nhưng bỏ sót 1961 trường hợp hủy phòng. Đặc điểm này cho thấy mô hình thận trọng hơn khi gán nhãn hủy và có thể phù hợp trong tình huống chi phí cảnh báo giả cao hơn chi phí bỏ sót.

6.3.3 XGBoost và CatBoost

XGBoost và CatBoost đạt kết quả trung gian giữa hai mô hình trên. XGBoost có 1206 trường hợp dương tính giả; con số này cần được đánh giá cùng số lượng âm tính giả và chi phí nghiệp vụ của từng loại sai số.

6.4 Phân tích rủi ro và chiến lược kinh doanh

Việc lựa chọn mô hình cần gắn với chi phí của các loại sai số trong hoạt động quản lý phòng.

6.4.1 Rủi ro vận hành

Dương tính giả (*false positive*) xảy ra khi mô hình dự đoán khách sẽ hủy nhưng khách vẫn đến nhận phòng. Nếu khách sạn bán lại phòng dựa trên dự đoán này, tình trạng vượt công suất có thể phát sinh, kéo theo chi phí bồi thường, chuyển khách và ảnh hưởng đến chất lượng dịch vụ.

Âm tính giả (*false negative*) xảy ra khi mô hình dự đoán khách sẽ đến nhưng đơn đặt phòng thực tế bị hủy. Trong trường hợp không kịp bán lại, phòng có thể bị bỏ trống và gây thất thoát doanh thu. Mức độ ưu tiên giữa hai loại sai số phụ thuộc vào công suất, mùa vụ và chính sách của từng khách sạn.

6.4.2 Đề xuất chiến lược ứng dụng

LightGBM được lựa chọn làm mô hình chính do đạt kết quả tổng thể và Recall lớp 1 cao nhất trong phạm vi thực nghiệm. Ngưỡng phân loại có thể được điều chỉnh từ mức mặc định 0,5 tùy theo chi phí của cảnh báo giả và bỏ sót. Việc nâng ngưỡng lên 0,7 có thể giảm dương tính giả nhưng đồng thời làm tăng âm tính giả; do đó, ngưỡng này cần được kiểm định trên tập xác thực và đánh giá bằng phân tích chi phí-lợi ích trước khi áp dụng.

Đối với các đơn được xếp vào nhóm nguy cơ cao, bộ phận chăm sóc khách hàng có thể liên hệ xác nhận lịch trình hoặc đề xuất chính sách đặt cọc phù hợp. Kết quả dự đoán nên được sử dụng như thông tin hỗ trợ và kết hợp với điều kiện vận hành thực tế, thay vì tự động quyết định việc bán dư phòng.

Chương 7

Kết luận và ứng dụng thực tiễn

7.1 Tổng kết giải pháp

Đồ án đã xây dựng một quy trình học máy khép kín (*end-to-end pipeline*) cho bài toán dự đoán khả năng hủy đặt phòng khách sạn. Hệ thống bao gồm các giai đoạn phân tích khám phá dữ liệu, tiền xử lý và hạn chế rò rỉ dữ liệu, huấn luyện nhiều mô hình, tinh chỉnh siêu tham số và đánh giá trên tập kiểm thử độc lập. Mã nguồn được tổ chức theo hướng đối tượng và phân tách thành các module chức năng nhằm hỗ trợ việc bảo trì, kiểm thử và tái lập quy trình thực nghiệm.

Trong phạm vi các mô hình và cấu hình được khảo sát, LightGBM đạt kết quả tổng thể cao nhất với Accuracy 83,25%, AUC 0,895 và Recall 0,6289 đối với lớp hủy phòng. Mức chênh lệch giữa các mô hình không lớn; do đó, LightGBM được lựa chọn cho hệ thống thử nghiệm dựa trên sự kết hợp giữa các chỉ số đánh giá, khả năng nhận diện lớp hủy và chi phí tính toán. Kết luận này chỉ áp dụng trong phạm vi tập dữ liệu và thiết kế thực nghiệm của đề tài.

7.2 Đề xuất chiến lược kinh doanh

Xác suất dự đoán của mô hình có thể được sử dụng như một nguồn thông tin hỗ trợ quyết định, thay vì thay thế hoàn toàn đánh giá của bộ phận vận hành. Việc triển khai cần kết hợp kết quả mô hình với chính sách kinh doanh, công suất phòng và chi phí của từng loại sai số.

7.2.1 Điều chỉnh ngưỡng quyết định

Ngưỡng phân loại cần được lựa chọn theo mục tiêu của hành động can thiệp. Đối với các biện pháp có chi phí cao hoặc có nguy cơ ảnh hưởng đến trải nghiệm khách hàng, việc nâng ngưỡng từ 0,5 lên 0,7 có thể làm giảm số trường hợp dương tính giả. Tuy nhiên, thay đổi này đồng thời có thể làm tăng số đơn hủy bị bỏ sót. Vì vậy, ngưỡng phù hợp cần được xác định bằng phân tích chi phí-lợi ích, đánh giá trên tập xác thực và kiểm tra độ hiệu chỉnh của xác suất dự đoán.

7.2.2 Chăm sóc khách hàng chủ động

Đối với các đơn đặt phòng được dự báo có nguy cơ hủy cao, bộ phận chăm sóc khách hàng có thể thực hiện bước xác nhận trước ngày nhận phòng hoặc đề xuất chính sách đặt cọc phù hợp. Các yếu tố như thời gian đặt trước dài, loại đặt cọc và phân khúc thị trường có thể được sử dụng để bổ sung ngữ cảnh cho quyết định. Chính sách can thiệp cần được áp dụng minh bạch và tránh gây bất lợi không hợp lý cho một nhóm khách hàng cụ thể.

7.2.3 Quản lý bán dư phòng

Xác suất hủy dự báo có thể hỗ trợ việc ước lượng số lượng phòng có khả năng được giải phóng và xây dựng chính sách bán dư (*overbooking*). Mức bán dư cần được xác định theo tổng xác suất hủy, năng lực bố trí phòng thay thế và chi phí phát sinh khi số khách đến vượt quá công suất. Do đó, kết quả mô hình nên được kết hợp với các ràng buộc vận hành thay vì chuyển trực tiếp thành số lượng phòng bán thêm.

7.3 Hạn chế của nghiên cứu

7.3.1 Phạm vi dữ liệu

Mô hình hiện chỉ sử dụng thông tin lịch sử trong tập dữ liệu đặt phòng và chưa tích hợp các biến ngoại sinh như thời tiết, sự kiện tại địa phương, biến động giá vận chuyển hoặc điều kiện kinh tế. Bên cạnh đó, dữ liệu được thu thập trong một phạm vi thời gian và nhóm khách sạn cụ thể nên kết quả có thể thay đổi khi áp dụng tại thị trường, thời điểm hoặc cơ sở lưu trú khác.

7.3.2 Khả năng giải thích mô hình

Các mô hình tăng cường gradient có cấu trúc phức tạp, khiến việc giải thích từng dự đoán khó khăn hơn so với các mô hình tuyến tính hoặc cây quyết định đơn. Chỉ số mức độ quan trọng của đặc trưng cung cấp thông tin ở cấp độ tổng thể nhưng chưa giải thích đầy đủ nguyên nhân của từng dự báo. Hạn chế này cần được xem xét khi kết quả mô hình được sử dụng để hỗ trợ các quyết định có ảnh hưởng trực tiếp đến khách hàng.

7.4 Hướng phát triển

Các nghiên cứu tiếp theo có thể mở rộng không gian siêu tham số bằng phương pháp tối ưu Bayes (*Bayesian optimization*) và đánh giá mô hình trên dữ liệu thu thập từ nhiều khách sạn hoặc nhiều giai đoạn thời gian. Việc tích hợp dữ liệu ngoại sinh cũng có thể giúp kiểm tra khả năng cải thiện năng lực dự báo trong những điều kiện thị trường khác nhau.

Bên cạnh đó, các phương pháp giải thích mô hình như SHAP, LIME hoặc phân tích hoán vị đặc trưng có thể được bổ sung để cung cấp thông tin ở cả cấp độ tổng thể và từng

dự báo. Sau khi hoàn tất kiểm định, mô hình có thể được triển khai dưới dạng API bằng FastAPI và tích hợp vào giao diện web nội bộ. Quá trình triển khai cần đi kèm cơ chế giám sát sai lệch dữ liệu, suy giảm hiệu suất và cập nhật mô hình định kỳ.